

DS-MINI-Design-울산캠퍼스_4반-이정인

U131 이정인

1. 데이터 형식

데이터 개요 : 배터리 수명 데이터를 인위적으로 넓게 분포 - 충전 조건을 다양화시킴

<실험 조건>

환경 챔버 : 30°C 항온 챔버에 48 채널 Arbin LBT 사이클러로 테스트

온도 측정 : Thermocouple을 부착하여 측정

내부 저항 : 충전 중 80% SOC 지점에서 $\pm 3.6\text{C}$ 펄스를 10회 인가

- 전압 강하량 / 전류 변화량 → 내부 저항 산출

충전 : 0~80% 까지 다양한 조합으로 1/2단계 고속 충전 진행

- 80~100% : 동일하게 1C CC-CV로 통일하여 진행

방전 : 4C CC-CV로 방전 - 모두를 통일하여 진행하기

수명 정의 : 초기 공칭 용량 (1.1Ah)의 80%인 0.88Ah일 때 사이클 수

1) 데이터 형식

```
batch = mat['batch']

# mat73은 list of dict, scipy는 structured array로 반환
# 아래 코드로 둘 다 동일하게 처리
if isinstance(batch, dict):
    # mat73: {'field': [val0, val1, ...]} 형태 → list of dict로 변환
    keys = list(batch.keys())
    n_cells = len(batch[keys[0]])
    batch = [{k: batch[k][i] for k in keys} for i in range(n_cells)]
    print("mat73 형식 → list of dict 변환 완료")

print(f"배터리 셀 수      : {len(batch)}")
print(f"타입              : {type(batch)}")
print(f"첫 번째 셀 키      : {list(batch[0].keys())}")

-----
mat73 형식 → list of dict 변환 완료
배터리 셀 수      : 46
타입              : <class 'list'>
첫 번째 셀 키      : ['Vdlin', 'barcode', 'channel_id', 'cycle_life', 'cycles', 'policy', 'policy_readable', 'summary']
```

2) 데이터 세부 구조

데이터 : 각각의 배터리에 대한 시계열 데이터가 cycle 단위로 늘어선다.

기본 구조 : Vdlin / (barcode / channel_id → 실험기기, 배터리 번호라 생략)
cycle_life(y) / cycles / policy / policy_readable / summary

summary : cycle 별로 최종 결과 값을 가지고 있는 테이블

- summary 구조 : 'IR', 'QCharge', 'QDischarge', 'Tavg', 'Tmax', 'Tmin', 'chargetime', 'cycle' 의 키를 가진 dict 형식

Cycle : 각 cycle에서 시간 별로 나타내어진 값

- Cycle 구조 : 'I', 'Qc', 'Qd', 'Qdlin', 'T', 'Tdlin', 'V', 'discharge_dQdV', 't' 의 키를 가진 dict 형식

2. Data 탐색 - EDA

1) Cycle Life 분포는 어떻게 생겼는가?

사전 진행 : 전체 파일을 다 사용하려면 너무 오래 걸리므로 전처리를 진행

1. 메타데이터 추출 → batch_meta.csv

- 내용 : cell 고유 식별자 / batch_id / 충전 정책 문자열 / cycle life


2. batch_summary.pkl : pickle 파일로 summary(cycle에 따른 결과로 요약)

- column : cell_key, cycle, QD, QC, IR, Tmax, Tavg, Tmin, charge_time

3. 10회차 / 100회차 전압 곡선 : pickle 파일로 10회/100회차 전압 시계열 곡선 저장

- 저장 요소 : 10회차 / 100회차의 Qdlin / Vdlin 시계열 데이터

1.1 150 ~ 2,300 사이클 Histogram



Batch	셀 수	평균 수명	표준편차	중앙값	최소값	최대값	단수명(<500)
Batch 1	46	844.7	184.6	858.5	534	1227	0.0%
Batch 2	39	565.7	222.2	472.0	392	1186	71.8%
Batch 3	44	1059.7	313.9	1005.5	541	1935	0.0%

Cycle : 최소 392 ~ 최대 1935 cycle에 걸쳐 분포함


1. 전체 분포 형태 : 대칭 정규 분포가 아니라 800~900 사이클 부부에 데이터가 몰림

- 데이터 형태 : 오른쪽이 긴 Right-Skewed
단수명과 장수명 그룹이 갈라지는 multimodal

2. 배치 별 형태 : batch 마다 분포의 형태가 다르다

- batch 1 : 단수명과 장수명 그룹 사이에 대부분이 위치하고 있음
- batch 2 : 단수명 데이터가 대다수를 차지함
- batch 3 : 장수명 데이터를 절반 정도 포함하고 있음

1.2 장수명(>1,000)/단수명(<500) 비율 확인



구분	count	mean	std	min	25% (Q1)	50% (중앙값)	75% (Q3)
Batch 1	46	844.7	184.6	534	703.2	858.5	914.2
Batch 2	39	565.7	222.2	392	439.5	472.0	508.5
Batch 3	44	1059.7	313.9	541	828.0	1005.5	1155.2
Total (전체)	129	833.7	315.0	392	559.0	828.0	1017.0

단수명 셀 : test set 1인 batch 2에서만 단수명 cell이 발견되었음

장수명 셀 : batch 1, 3에서 장수명 cell이 발견되었음

총 비율 : 장수명 cell이 27.9%, 단수명 cell이 21.7%의 비율을 차지한다.

1.3 이상치 셀 식별 - 왜 유독 짧은가?

결측 셀 : cycle_life == NaN인 경우

1번 : 애초에 반영되지 않은 경우

- 100cycle만 하고 끝내버린 경우
- Slowcycle : 중간에 C/10, C/20의 진단 사이클을 삽입하여 테스트 루틴 다름

2번 : 너무 오래 되서 반영 안함 : 2000번 이상 돌렸는데 EOL이 80% 이하로 안떨어짐

이상치 셀 : 극단적으로 빠르게 퇴장하는 하위 5개 cell을 관측

극단적인 단수명 : batch 2에 있는 cell들 중 극단적인 단수명을 가진 cell들은 충전 속도가 5~6C 인 부분이 대부분인 cell들로, 충전 속도가 빠를 수록 cycle 수를 감소시킨다는 것을 유추 가능하다.

극단적인 장수명 : 초기 내부 저항이 낮으며, 전류 밀도가 지나치게 높은 부분이 없는 등의 특징이 하나는 있다는 점에서 충전 속도 - 전류에 의한 열의 발생이 영향을 미치는 것을 유추 가능하다.

결론


학습 대상인 Batch 1은 단수명(<500회) 셀이 전무(0.0%)한 반면, 주요 테스트 대상인 Batch 2는 단수명 셀이 71.8%로 지배적인 극명한 배치 효과(Batch Effect)가 존재한다.

따라서 모델은 '학습 시 경험하지 못한 조기 열화 영역'을 테스트 단계에서 외삽(Extrapolation)해야 하는 높은 일반화 난이도를 갖는다.


이를 극복하기 위해서는 단순 용량 스칼라나 운전 조건을 암기하는 모델을 지양하고, 조기 열화(Knee Point 촉발)의 전기화학적 전조 증상을 직접 포착할 수 있는 $\Delta Q(V)$ \Delta Q(V) 전압 변화 피쳐 중심의 모델링 전략이 필수적이다.

2) 열화 곡선 - 방전 용량이 어떻게 감소하는가?

2.1 사이클 별 Qd 추이 시각화



전체 수명 궤적 : 시작 지점은 1.1Ah로 거의 일치하며, EOL에 도달하는 시점은 다르다



- 100cycle 까지 : 오히려 용량이 증가하는 모습을 보인다? → 특이 현상
 - 원리론 : 원통형 배터리는 제조 시 short를 막기 위해 음극을 더 넓게 설계하는 overhang이 존재함 → 잉여 리튬 이온으로 인해 기인한 현상


2.2 열화 속도가 일정한가, 가속되는가?

열화 속도 : 공통적으로 나타나는 개형으로, 2개의 단계로 구분 가능하다.

- 1단계 : 처음은 선형으로, 수명의 7~80% 까지는 매우 완만하게 감소한다
- 2단계 : 이후 급격히 꺾이며 EOL로 도달한다.

2.3 Knee point - 급격한 열화 시작점 탐색

Question 2. Knee Point Detection via Bilinear Piecewise Regression




단수명 / 장수명 / 중간 공통 : 약 70~80% 구간에서 knee point가 존재함

결론

1. 초기 Qd 스킨라 값으로는 장수명 cell / 단수명 cell 구분이 불가능하다.
2. 공통적으로 EOL에 도달하는 시간의 72~78%에서 knee point가 발생한다
3. 핵심 과제 : 만약 100cycle을 통해 값을 알 수 있다면 효율적인 실험이 가능할 것

3) $\Delta Q(V)$ 곡선 - 초기 사이클에서 차이가 보이는가?



3.1 사이클 100번 - 사이클 10번의 Q(V) 차이 계산

3.2 장수명 셀 vs 단수명 셀의 ΔQ 형태 비교

Q(V) 차이 : 단수명 집단과 장수명 집단의 Q(V) 차이 비교

장수명 집단 : 요동침이 적어 안정적인 모습을 보임

단수명 집단 : 2.8~3.2V 구간에서 심각하게 왼쪽으로 밀려나서 분산이 극대화됨

3.3 이를 구분할 수 있는 통계값으로 피쳐 추출


Q(V) 차이 : 단수명 - 장수명 집단 전체를 아울러 볼 때 왼쪽으로 크게 있는 것으로 보아, log 채택

$\log_{10}(\text{분산}(\Delta Q(V)))$: 사실상 직선에 가까운, 높은 상관 관계를 가지기에 log값을 취한 Q(V) 차이의 분산을 피쳐로 사용할 수 있다.

4) 충전 조건 (C-rate)과 수명의 관계는?


4.1 충전 프로토콜별 평균 수명 비교

1단계 : 단순히 1단계 충전 속도를 측정하였을 때 상관 계수가 0에 가까운, 수평선에 가까운 개형이 보임




4.2 고속 충전 셀이 정말 수명이 짧은가?

charge time : 비교적 높은 상관 계수의 충전 시간 - cycle life의 관계성을 보이나, 상과 $\downarrow$ 계수가 0.3 정도로 완전한 상관 관계를 가진다고 볼 수는 없음



4.3 충전 전류 패턴과 열화 속도 상관 분석

온도 조건 : 주변 온도 자체가 항온 챔버라는 조건으로 인해 온도의 분포가 cycle life에 영향을 직접적으로 미치지 않는 것으로 보임. 다만 I^2R 의 발열 항과 관련될 수는 있다.




결론

1. 충전 프로토콜 : 단순히 1단계 충전보다는 충전 시간에 보다 높은 상관 관계를 보임

2. 열화 속도 상관 분석 : 실험 환경으로 인해 적은 영향을 끼치는 것으로 보이나, 내부 저항 등 영향으로 다른 변수에 복합적인 영향을 미칠 수 있음

5) 상관관계 - 어떤 신호가 수명과 연관되어 있는가?



5.1 초기 사이클 피쳐들과 Cycle Life 상관 계수 확인

초기 사이클 피쳐 : 100 cycle 까지 피쳐들과 cycle life의 상관 계수는 다음과 같다.

log_cycle_life	
min_dq	0.888001
log_var_dq	-0.886413
mean_dq	0.860797
QD_mean	-0.540553
IR	-0.353998
chargetime	0.318970
Tavg	0.250413
Tmax	-0.016106
QD_diff_100_1	0.014023

5.2 가장 강한 관계 식별

가장 강한 관계 : min_dq / log_var_dq

- min_dq : 방전되면서 100th cycle / 10th cycle에서 Q 차이가 가장 클 때의 값이 높은 상관 관계를 가짐
- log_var_dq : 초기 사이클에서 100th cycle / 10th cycle에서의 Q 차이가 높은 상관 관계를 가짐

5.3 멀티콜리너리티 문제 확인

다중공선성 : 파생 / 독립 변수 간에 상관 관계가 존재 시 다중공선성이 나타나 배제해야 한다.

- min_dq / mean_dq / log_var_dq : 사실상 선형 종속(min의 절댓값이 클 수록 분산은 자연스럽게 커지게 되기 때문에)
- T_mean / T_max : 평균이라는, 선형 연산을 진행하여 상관 관계가 높을 수 밖에 없다.

결론

1. 단순 선형 회귀 배제 : 다중공선성으로 인해 하나의 원인이 여러 피처에 적용되는 현상이 발생함
2. L1/L2 정규화(lasso / Ridge 정규화) : 손실 함수에 가중치 크기에 대한 패널티를 부여 → 정규화 진행
 - 필요성 : 불필요한 중복 피처를 걸러내고, 계수 크기 엄격하게 제한하기

3. 모델 설계 전략

유의미 변수 선별 - 도메인 기반 피처 설계

target variable : cycle life에 log를 취해 왜도를 정규화한다.

Lv1. 단순 분산 모델 → log_var_dq 선택

- 초기 모델로서, 1개의 피처로 수명의 연관성을 증명

Lv2. 방전 모델 → log_var_dq + min_dq + kurt_dq 선택

- dQ 곡선의 분산에 극소 / 첨도를 추가하여 곡선의 개형에 따른 복합적인 연관성을 증명

Lv3. Full model → Lv2 + charge 시간 + IR + Tmax

- 내부 저항과 온도, 외부 가혹도의 변인을 추가하여 초기값 등 환경을 설정함에 따라 성능을 높이는 단계

모델 선택

선택 모델 : Regression model

- 선택 이유 : 연속적인 cycle life의 개형을 찾아 EOL을 예측하는 것이 목적이므로, 추세를 관찰하고자 하는 Regression model이 이상적임

세부 모델 조건 : Batch 특성으로 인해 cycle life의 경향성을 실제 시료 외에서 연속하여 측정하여야 한다.

- Elastic Net = Lasso(L1) + Ridge(L2)

1. 다중공선성 방지 : 일반 회귀를 사용할 경우 피처 값의 다중 공선성으로 인해 가중치나 부호가 뒤집히거나 폭발하는 경우가 있다. 그러므로 가중치를 안정적인 크기로 유지할 수 있는 Elastic Net을 사용한다.
2. 소표본의 과적합 방지 : 시계열 * cycle 수로 인해 시료가 많아보이나 실제 cell의 갯수는 124개로 전체 dataset 자체가 작아 노이즈의 암기가 있을 수 있다. 이를 방지 가능하다.
3. 연속 외삽 보장 : 학습 데이터인 Batch 1에서는 단수명 값이 없는 반면 test 데이터인 Batch 2는 많은 단수명 값이 존재하므로, 트리구조에서 발생하는 예측값이 끊기는 문제를 방지 가능하다.